빅데이터 분석 종합실습

# 인도 중고차 가격 예측 모델 개발




조원 김성호 · 박시은 · 배희정 · 윤국한 · 정경원 · 황하은

2026. 05. 29

# 인도 중고차 가격 예측 모델 개발



## 비즈니스 배경

인도 중고차 시장은 기존에 비해 다양한 차종에 대한 선호가
증가하면서 차급 / 성능별 시장 **세분화**가 필요해지고 있음



## 핵심 문제

중고차는 Brand·연식·주행거리·상태에 따라 가격 편차가
매우 크고 불확실성이 높아 **적정 가격 산정**이 어려운 상황임.



## 분석 목표

일반 차량 시장과 고성능 차량 시장을 분리하고,
각 시장에 최적화된 가격 **예측 모델** 도출

# 변수 구성 및 데이터 품질 현황

| 구 분 | 변수 | 변수설명 | Data Type |
|---|---|---|---|
| 목표변수 | Price | 중고차 가격(단위 : 1,000 원) | 연속형 |
| 설명변수 | Name | 자동차의 브랜드와 모델의 이름 | 범주형 |
| 설명변수 | Location | 자동차를 팔거나 구매할 수 있는 위치 | 범주형 |
| 설명변수 | Year | 모델의 년도 혹은 버전 | 연속형 |
| 설명변수 | Kilometers_Driven | 이전 소유주의 차량 주행거리(Km) | 연속형 |
| 설명변수 | Fuel_Type | 자동차의 사용연료의 종류 | 범주형 |
| 설명변수 | Transmission | 자동차의 사용 변속기의 종류 | 범주형 |
| 설명변수 | Owner_Type | 소유권이 직접 소유인지, 중고 소유인지 여부 | 범주형 |
| 설명변수 | Mileage | 자동차 회사가 제공하는 표준주행거리(kmpl) | 연속형 |
| 설명변수 | Engine | 엔진의 배기량(cc) | 연속형 |
| 설명변수 | Power | 엔진의 최대 출력(bhp) | 연속형 |
| 설명변수 | Seats | 차의 좌석 수 | 연속형 |
| 설명변수 | New_Price | 뉴 모델의 가격 | 연속형 |

**7,253**

원본 데이터 행

→ **5,871**

정제 후 데이터

도메인 기준 이상치 제거 + Luxury 분리

**13** 개 분석 변수 수

# 단계별
# 분석 프로세스

EDA → 모델링 → 선정 & 개선

01

## 데이터 불러오기 & 구조 확인

df.info(), describe()로 기본 현황 파악

02

## 1차 정제 & 파생변수 생성

단위 제거·Brand, Vehicle_Age, Luxury 생성

03

## 결측치 & 이상치 처리

Price 결측 제거 + 도메인 기준 / IQR 비교

04

## 탐색적 분석 (EDA)

Boxplot · Scatter · ANOVA · Pearson 상관 · VIF

05

## 모델링 & 성능 비교

LR · Random Forest

06

## Best Model 선정 & 개선 제안

MAE / RMSE / $R^2$ 종합 비교 후 개선 방안 도출

# 결측치 · 이상치 처리 및 파생변수 생성

STEP 01

### 1차 정제 (단위 제거·브랜드 추출)

· Engine, Power, Mileage 컬럼에서 단위 문자열 제거 후 float 변환
· Name 첫 단어를 Brand 컬럼으로 분리 (예: Maruti, Hyundai)

STEP 02

### 도메인 기반 이상치 제거

· Km_Driven ≥ 6,000,000: 입력 오류로 판단 → 제거
· Mileage = 0 및 Seats = 0: 비정상 값 → 제거
· Price 결측 행 제거 (타겟 변수이므로 대체 불가)

STEP 03

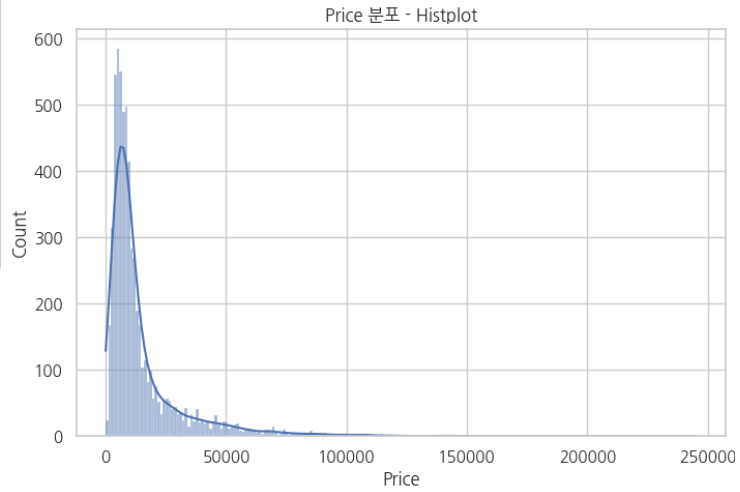
### 파생변수 생성

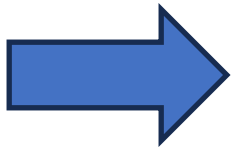
· Vehicle_Age = 2026 − Year (차량 연식)
· Luxury = 1 if (Engine ≥ 3,123cc) OR (Power ≥ 232.75bhp) — upper bound기준

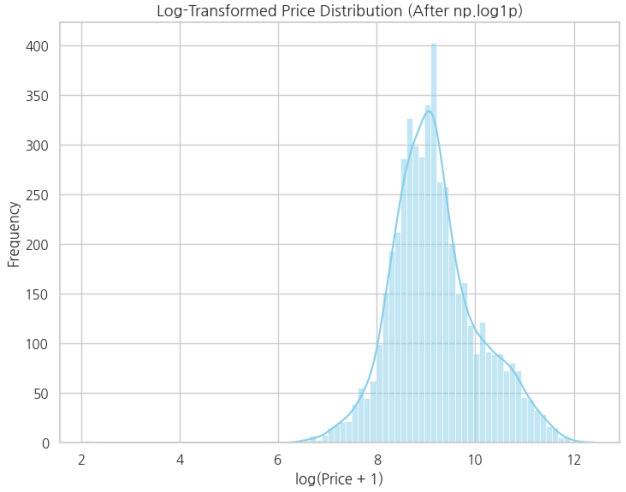
### 정제 결과 요약

| | |
|---|---|
| 원본 → 정제 후 | 7,253 → 6,130 → 5,871 행 |
| 제거 기준 | 도메인 + 중복 + 비정상데이터 |
| 최종 파생변수 | Vehicle_Age, Luxury |

# Price 분포 탐색

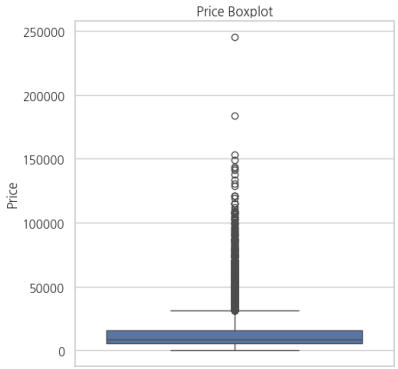


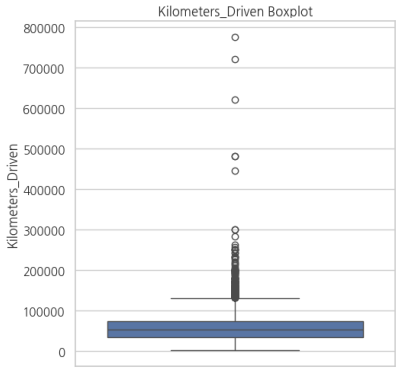



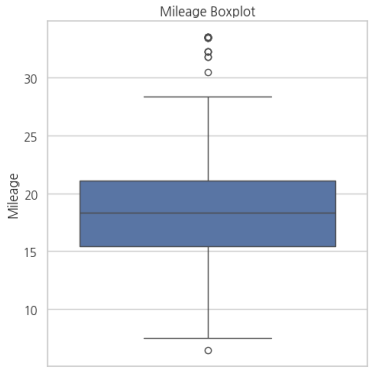


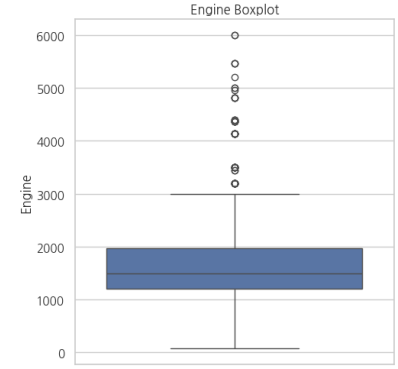

**원본 Price는 오른쪽으로 심하게 치우쳐 소수 고가 차량이 평균을 끌어올림**
**→ 선형 모델 학습에 유리하도록 log1p 변환하여 정규분포에 근사**

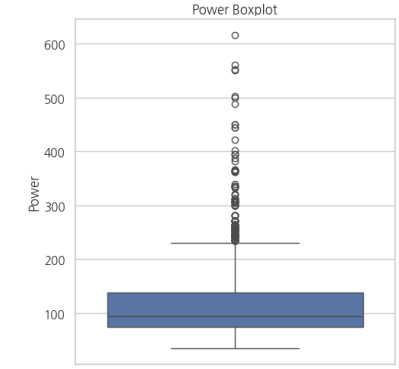
# 데이터 분포 확인

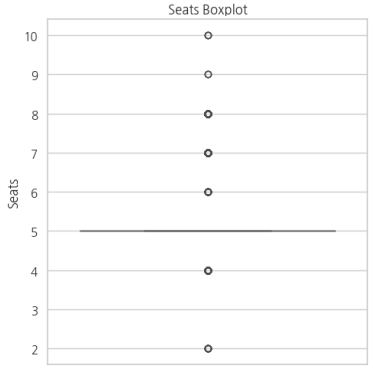


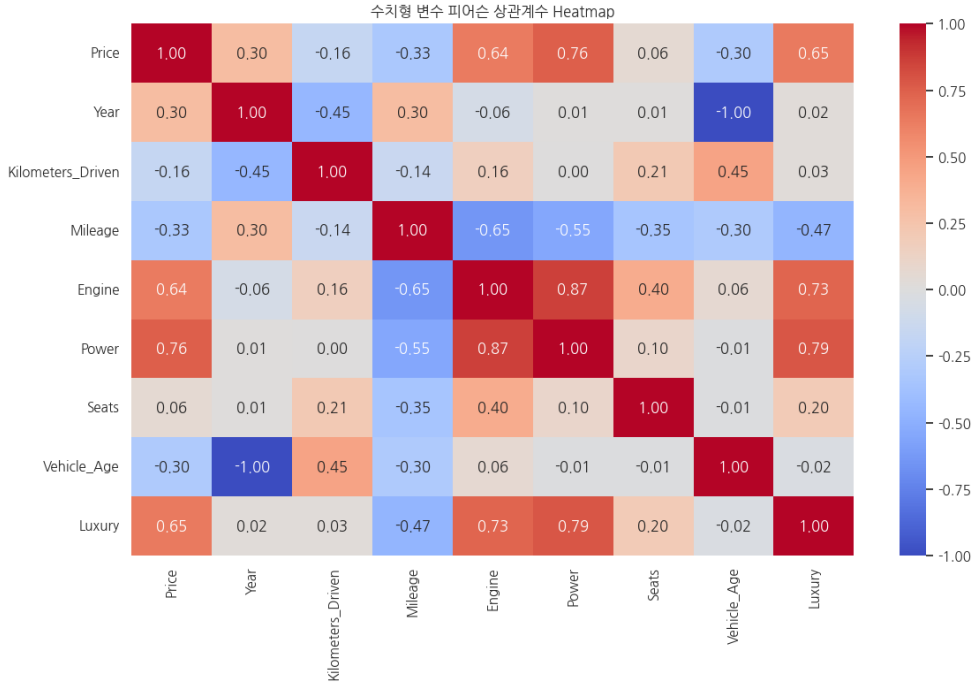




- Killometers_Driven에서 6,000,000km 이상 주행 차량 삭제

- Mileage, Seats가 0인 행
  → 비정상 데이터로 간주하여 삭제

- Engine과 Power의 이상치가 데이터에서 많은 비중을 차지하고 있음을 확인

# 상관관계 Heatmap 확인

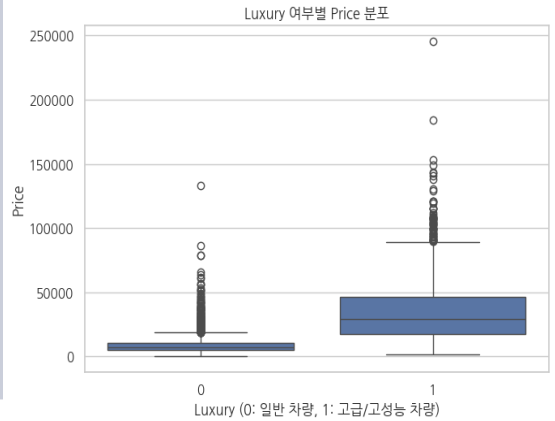



## 💡 Engine & Power의 상관관계

▶ Engine과 Power의 상관관계가 0.87로 매우 큼
→ Engine이 커지면 Power도 커진다.

▶ Engine or Power의 이상치들을 Luxury로 묶어 다른 시장으로 분리함.
→ 이상치 처리 & 다중공선성 완화

# Luxury 파생변수 효과







### 💡 Engine & Power가 큰 차들은 일반 차량에 비해 비싸게 거래됨

Engine · Power가 큰 차는 가격이 높아진다.
(Price와의 상관계수 Engine: 0.64, Power: 0.76)
→ 좌측 boxplot을 보면 평균적으로 더 비싼 가격에 거래됨을 확인할 수 있다. (box와 이상치 값이 더 높게 위치함)
→ 인도의 소득수준이 높은 지역에서 많이 거래 된다.



# 예측 모델 개발 & 성능 비교 결과

| 모델 | MAE | RMSE | $R^2$ |
|---|---|---|---|
| Random Forest | 2112.13 | 4579.96 | 0.88 |
| Linear Regression | 2377.24 | 4587.90 | 0.88 |

💡 최종 선택: Random Forest
(평균 오차: 약 211만 원, 모델 설명력 88%)

# 예측 모델 개발 & 성능 비교 결과

| | dataset | model | MAE | RMSE | R2 |
|---|---|---|---|---|---|
| 1 | 이상치 미제거 데이터 | Random Forest | 2399.447619 | 5463.836203 | 0.892364 |
| 0 | 이상치 미제거 데이터 | Linear Regression | 4523.725621 | 7868.617740 | 0.776767 |

| | variable | VIF |
|---|---|---|
| 0 | Year | inf |
| 1 | Vehicle_Age | inf |
| 4 | Engine | 6.513375 |
| 5 | Power | 5.396716 |

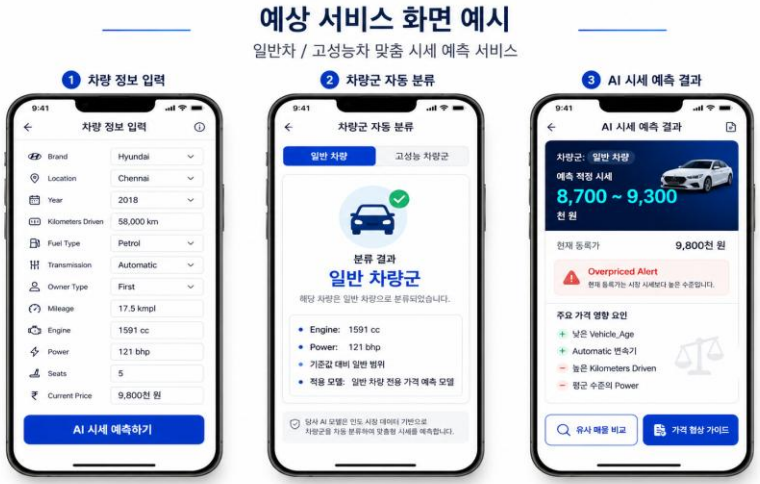


| | variable | VIF |
|---|---|---|
| 0 | Year | inf |
| 1 | Vehicle_Age | inf |
| 4 | Engine | 5.642794 |
| 5 | Power | 4.018987 |

- 기존 Luxury 분류 없이 모델링 했을 때와 설명력은 비슷한데, MAE가 감소했다

- Engine & Power 이상치를 Luxury로 분류한 다음 VIF값이 감소해 다중공선성 가능성을 낮췄다.

# 모델 활용 방안




•대중 소비자용 적정 시세 예측 가능
•고객에게 현실적인 가격 판단 기준 제공
•차량 성능별 시장을 나눠 차별화된 서비스 제공 가능

# 결론 & 대안 제시

분석 결과 기반 인사이트

**C1** 최종 모델 선정

Random Forest → $R^2 = 0.88$, MAE ≈ 211 천 원

**C2** 중고차 시장 분리 필요성 제시

시장을 분리했을 때 모델의 성능 증가 확인을 통해 시장 분리가 필요함을 시사한다.

**C3** 가설 검증 결과

브랜드·변속기·연료·위치 모두 ANOVA $p < 0.05$ — 유의미한 변수 확인

## 대안 및 모델 성능 향상 방안

| | | |
|---|---|---|
| 1 | Gradient Boosting 적용 | XGBoost / LightGBM으로 앙상블 성능 추가 향상 기대 |
| 2 | 하이퍼파라미터 튜닝 | GridSearchCV / RandomizedSearch로 최적 파라미터 탐색 |
| 3 | 추가 Feature Engineering | New_Price 보완 활용, Brand 세부 등급화, 지역 클러스터링(Tier-2 수요 62% 반영) |
| 4 | K-Fold 교차검증 (k=5) | 단일 분할 대비 안정적 일반화 성능 확보 |

# 분석 과정에서 배운 점 & 느낀 점

**김성호**

데이터 정제 과정에서 단순히 이상치를 제거하는 것이 아니라, Luxury 차량이라는 도메인 지식 기반의 파생변수로 전환한 점이 인상 깊었습니다. 데이터를 다루는 것도 결국 맥락을 이해하는 일이라는 걸 배웠습니다.

**박시은**

상관분석을 통해 Engine과 Power의 상관계수가 0.87에 달한다는 것을 확인했을 때, 숫자가 실제 자동차 도메인 상식과 정확히 맞아떨어지는 경험이 흥미로웠습니다. EDA가 단순한 탐색이 아니라 인사이트 발굴의 과정임을 느꼈습니다.

**배희정**

Random Forest가 최종 선정된 이유를 단순히 성능 수치로만 보지 않고, 과적합 방지도 고려하는 과정이 의미 있었습니다. 모델 선정도 결국 판단의 영역임을 깨달았습니다.

**윤국한**

인도 중고차 시장 배경을 조사하면서, 데이터 분석 프로젝트가 단순한 모델링을 넘어 실제 비즈니스 문제와 연결된다는 점을 실감했습니다. 분석의 당위성을 먼저 세우는 것이 얼마나 중요한지 배웠습니다.

**정경원**

전처리 단계에서 결측값 처리 하나하나에도 근거가 필요하다는 점이 처음엔 번거롭게 느껴졌지만, 나중에 모델 성능으로 그 차이가 드러났을 때 꼼꼼한 정제의 중요성을 다시 한번 확인했습니다.

**황하은**

IQR 기준 일괄 삭제 대신 도메인 기반 정제를 선택한 결정이 프로젝트 전반의 방향을 바꿨다고 생각합니다. 분석가의 판단이 결과에 미치는 영향을 직접 체험한 값진 경험이었습니다.

감사합니다.

# 인도 중고차 가격 예측 모델 개발

조원 김성호 · 박시은 · 배희정 · 윤국한 · 정경원 · 황하은

POSCO 청년 AI · Big Data 아카데미 | 2026